

RELATÓRIO TÉCNICO: ÉTICA, GOVERNANÇA E EQUIDADE EM VISÃO COMPUTACIONAL

1. Contextualização Ética e IA Responsável

A introdução de sistemas de Visão Computacional no diagnóstico médico exige governança de dados rigorosa (*Responsible AI*). Como os modelos baseados em Redes Neurais Convolucionais (CNNs) são altamente dependentes da representatividade dos dados, assimetrias demográficas ou clínicas podem fazer com que o algoritmo automatize e amplifique preconceitos em escala. O objetivo desta auditoria é identificar os potenciais vieses do pipeline do **CardiolA** e estabelecer práticas de mitigação para garantir um diagnóstico seguro, equitativo e transparente.

2. Análise de Limitações e Vieses do Dataset

A auditoria do pipeline do CardiolA identificou três limitações críticas com potencial de induzir o modelo a erros sistemáticos:

- Desbalanceamento de Classes (Viés Clínico):** O dataset reflete a escassez de dados do mundo real da saúde, apresentando **414 amostras Saudáveis contra apenas 30 de Cardiomegalia** (menos de 5% do suporte). Esse desbalanceamento força a rede a focar na classe majoritária, inflando a acurácia global (71%), mas mascarando o apagamento da Cardiomegalia, com *Recall* zerado (0.00) — um risco crítico de falsos negativos.
- Viés Demográfico e de Representatividade:** Variações anatômicas associadas ao gênero e à idade (como densidade do tecido mamário ou alterações senis na silhueta cardíaca) alteram a assinatura visual do Raio-X. A sub-representação desses grupos reduz a capacidade de generalização da IA.
- Viés de Artefato (*Confounding Variables*):** Imagens obtidas por diferentes marcas de aparelhos ou dispositivos portáteis de UTI trazem variações técnicas (contraste, marcas d'água). A rede pode sofrer o fenômeno de *confounding*, associando o ruído técnico do equipamento portátil à presença de patologia, em vez de analisar os padrões puramente biológicos do tórax.

3. Métricas de Equidade (*Fairness Metrics*) Aplicadas

Para garantir a paridade de desempenho entre diferentes subgrupos demográficos (G), monitora-se duas métricas formais:

- Igualdade de Oportunidades (*Equal Opportunity*):** Garante que a taxa de Verdadeiros Positivos (TPR / Sensibilidade) seja equivalente para todos os grupos protegidos (ex: Homens e Mulheres). Matematicamente:

$$P(\hat{Y} = 1 \mid G = \text{Masc}, Y = 1) = P(\hat{Y} = 1 \mid G = \text{Fem}, Y = 1)$$

$$P(\hat{Y} = 1 \mid G = \text{Masc}) = P(\hat{Y} = 1 \mid G = \text{Fem})$$

Para neutralizar os vieses e alinhar o CardiolA com as diretrizes internacionais de governança, o plano de ação atua em três camadas:

- **Pré-processamento:** Aplicação de *Data Augmentation* direcionado e *Oversampling* físico nas pastas de treino das classes minoritárias (*Cardiomegalia* e *Infiltrado*) para equilibrar os lotes, associado ao corte padronizado (*cropping*) para eliminar textos e artefatos de borda.
- **Processamento:** Injeção da função `compute_class_weight` do Scikit-Learn no método `.fit()` do TensorFlow. Isso eleva matematicamente o custo do erro nas patologias, forçando os gradientes da DenseNet121 a penalizarem severamente os erros contra as classes menores.
- **Pós-processamento e Transparência:** Integração de mapas de ativação de classe (**Grad-CAM**). O Grad-CAM gera um mapa de calor sobre o Raio-X, revelando quais regiões anatômicas foram decisivas para o veredito da IA. Isso permite uma auditoria humana em tempo real pelo médico, validando se o modelo decidiu com base na anatomia ou em ruídos técnicos da imagem.

5. Conclusão da Auditoria

Sob a perspectiva da governança, o CardiolA atende aos critérios de transparência ao expor com clareza as limitações de suas métricas internas. A escolha da arquitetura **DenseNet121** reforça o compromisso ético do projeto: suas conexões densas reduziram o descompasso de domínio e preservaram o aprendizado das texturas patológicas de forma mais justa que os blocos convolucionais simples, consolidando-se como um *baseline* seguro e auditável para o ecossistema de saúde.