

RELATÓRIO TÉCNICO: ASSISTENTE CARDIOLÓGICO VIRTUAL (CARDIOIA)

1. Resumo dos Resultados

O pipeline de testes avaliou duas abordagens de Visão Computacional para a classificação multiclasse de Raio-X de tórax (*Cardiomegalia*, *Infiltrado* e *Saudável*). Ambos os modelos alcançaram uma **Acurácia Global de 71%** no conjunto de teste oculto (564 imagens), superando o patamar de chute aleatório (33.3%). Contudo, as arquiteturas exibiram comportamentos opostos na extração de características internas.

2. Tabela Comparativa de Métricas Globais

Métrica Global	CNN Desenvolvida do Zero	Transfer Learning (DenseNet121)
Acurácia Geral	71%	71%
Macro Avg (F1-Score)	30%	36% (Superior)
Weighted Avg (F1-Score)	63%	66% (Superior)

3. Análise Crítica por Classe Clínica

A. Classe Majoritária (Saudável)

Ambos os modelos demonstraram alta robustez para identificar pacientes sem achados patológicos, consolidando um F1-Score idêntico de **0.83**.

- DenseNet121:** Precisão de 76% e Recall de 92%.
- CNN do Zero:** Precisão de 74% e Recall de 95%.

Impacto Clínico: Essa performance valida o sistema como uma excelente ferramenta de **Triagem Automatizada**, capaz de reduzir filas de espera hospitalares ao liberar os casos normais com alta confiabilidade.

B. Classe Minoritária (Infiltrado)

Nesta patologia pulmonar sutil, a **DenseNet121 provou sua superioridade estrutural**.

- A **CNN do Zero** falhou em capturar a opacidade difusa, obtendo F1-Score de apenas **0.08** (Recall de 0.05).
- A **DenseNet121** elevou o F1-Score para **0.24** e o Recall para **0.17**, com a Precisão saltando para **38%**.

Impacto Clínico: Os blocos densos com reaproveitamento de recursos (*feature reuse*) da DenseNet121 permitiram propagar detalhes microscópicos da textura de "névoa" do infiltrado, algo que as camadas simples da CNN do zero negligenciaram.

4. Auditoria Clínica: Justificativa para a Classe "Cardiomegalia" (Métricas 0.00)

O resultado de **0.00** para a Cardiomegalia em ambas as abordagens é tecnicamente justificado por fatores estruturais do cenário médico real:

1. **Escassez Extrema de Dados:** O conjunto de teste contou com **apenas 30 amostras** de Cardiomegalia frente a **414 amostras** de pacientes Saudáveis (menos de 5% do total). O volume absoluto é insuficiente para redes profundas generalizarem o padrão anatômico da silhueta cardíaca aumentada.
2. **Efeito de Limiar da Camada Softmax:** Sob desbalanceamento crítico, as probabilidades finais pendem sutilmente para a classe majoritária. Ao aplicar o `np.argmax`, as predições limítrofes da Cardiomegalia acabam sendo engolidas matematicamente.

5. Plano de Mitigação (Governança e Ética em IA)

Para evoluções futuras do CardiolA, propõe-se:

- **Oversampling Estruturado:** Replicação física das imagens de Cardiomegalia e Infiltrado nas pastas de treino (/train) para equilibrar numericamente os lotes (*batches*).
- **Ajuste de Limiar Médico:** Substituição do `np.argmax` por um vetor de sensibilidade ponderada (ex: priorizar a patologia se a probabilidade dela passar de 30%).
- **Implementação da Focal Loss:** Substituição da função de perda padrão para forçar o otimizador a focar o aprendizado nas classes difíceis (patologias).

6. Conclusão e Seleção do Modelo

A arquitetura baseada em **Transfer Learning (DenseNet121)** foi a selecionada para a exportação definitiva do arquivo .h5 e integração com a API Flask / Aplicativo Mobile.

Justificativa Científica para a Escolha da DenseNet121: A seleção da DenseNet121, em detrimento de modelos como VGG16 ou ResNet50, baseou-se nas propriedades estruturais de seus *Dense Blocks* (Blocos Densos). Enquanto redes tradicionais realizam a soma de recursos, a DenseNet estabelece conexões diretas de cada camada com todas as camadas subsequentes. Esse mecanismo de reaproveitamento de recursos (*feature reuse*) impede o desvanecimento do gradiente. Na radiologia, onde os achados clínicos dependem de nuances microscópicas de pixels e texturas sutis, a DenseNet121 atua como o padrão-ouro da literatura médica, superando a capacidade de extração de características de estruturas convolucionais convencionais.

O modelo exibiu maior maturidade estatística (Macro Avg de 36% vs. 30%), mitigando o descompasso de domínio de forma mais eficiente e posicionando-se de forma ética e segura para ambientes de triagem radiológica.