

RELATÓRIO TÉCNICO: PIPELINE DE PRÉ-PROCESSAMENTO DE DADOS VISUAIS

Curso: Inteligência Artificial

Projeto: Cardiola — Sistema Inteligente de Triagem Radiológica (Fase 4)

Grupo: Giulia Bugatti Fonseca, Mahmod Ahmad Issa, Matheus Cardoso Oliveira Lima, Silas Fernandes de Souza Fonseca

1. Objetivo e Base de Dados

O módulo de Visão Computacional do Cardiola realiza a classificação multiclasse de Raios-X de Tórax em três categorias: Cardiomegalia, Infiltrado Pulmonar e Saudável. O protótipo utiliza um subconjunto amostral do dataset público NIH Chest X-ray-14 (via Kaggle), que apresenta desafios reais de ruído e desbalanceamento severo comuns no cotidiano hospitalar.

2. Pipeline de Pré-processamento Técnico

O fluxo de engenharia de dados visuais preparou as matrizes de pixels brutas através de três etapas sequenciais:

- Redimensionamento Espacial (Resize): Todas as imagens foram padronizadas para 256/256 pixels (RGB). Essa operação reduziu a dimensionalidade para 196.608 atributos de entrada, preservando a silhueta cardíaca e as texturas pulmonares dentro de limites saudáveis de consumo de memória (RAM/VRAM).
- Normalização de Escala Diferenciada: * *CNN do Zero*: Escalonamento linear simples ($\text{rescale} = 1./255$) para comprimir os pixels no intervalo $[0.0, 1.0]$.
 - *DenseNet121*: Uso da função nativa da arquitetura para centralizar e escalonar os pixels com base no histórico do dataset ImageNet.
 - *Justificativa*: Estabiliza o gradiente no *backpropagation*, acelera a convergência do otimizador Adam e evita a explosão de valores.
- Aumento de Dados Controlado (Data Augmentation): Aplicação em tempo de execução de rotações de até 15° e deslocamentos (*shifts*) de até 10° . Técnicas agressivas como espelhamento vertical foram descartadas para evitar anomalias biológicas impossíveis, simulando apenas variações reais de posicionamento do paciente no aparelho de Raio-X.

3. Organização e Portabilidade dos Dados

O dataset foi segmentado de forma isolada e mutuamente exclusiva dentro do diretório `dataset_estruturado/`, utilizando a biblioteca `os.path` para garantir caminhos relativos dinâmicos (portabilidade universal entre os integrantes e o professor):

- Treino (`/train`): Ajuste ativo de pesos e vieses das redes.

- Validação (/val): Monitoramento passivo de perdas para controle de callbacks (EarlyStopping e ReduceLROnPlateau).
- Teste Oculto (/test): Bloco isolado com 564 exames, acionado uma única vez ao final do pipeline para extração das métricas reais da banca.

4. Mitigação de Viés de Dados (Correção de Métricas Zeradas)

Devido à escassez crítica de exames de Cardiomegalia no conjunto de testes, os modelos iniciais tendiam a ignorar a patologia para reduzir a perda global, zerando o *Recall* e o *F1-Score*. A engenharia de dados corrigiu esse viés acionando duas abordagens no notebook:

1. Pesos Inversos de Classe (class_weight): Penalização matemática severa aplicada ao gradiente para cada erro cometido nas classes minoritárias (doentes).
2. Focal Loss: Substituição da perda tradicional por uma função modulada que atenua o peso de acertos fáceis (Saudável) e força a rede a focar nas texturas complexas das patologias.

Resultado: O pipeline garantiu que o modelo extraísse características úteis de todas as categorias, eliminando a métrica zerada e gerando um arquivo .h5 seguro e calibrado para rodar no aplicativo mobile.